AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad İkra Aslan | Grup Gece-B | Tarih 06.11.2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Helezon Motoru

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı: Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?**

   Helezon içine giren yabancı bir cisme veya tıkanmaya model OK verse bile motor sürücüsündeki bağımsız akım ve tork sınırı ile mekanik sıkışma sensörü ikinci kontrol olarak devreye girip helezonu durdurmalı ve yeniden başlatma için operatör onayı istenmelidir.

2. **Girdi manipüle edildi: Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?**

   Tozlanma veya arıza nedeniyle kamera görüntüsünün donması ya da bozulması görüntü kalite ve sinyal izleme kontrolüyle fark edilir. Şüpheli veri geldiğinde yapay zeka kararı devre dışı bırakılarak sistem güvenli duruşa alınır ve operatöre uyarı verilir.

3. **Confidence düştü: Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?**

   Güven eşiği en az yüzde 85 olmalıdır. Bu değerin altına düşüldüğünde model kararına güvenilmez, besleme yavaşlatılarak klasik sensör tabanlı kontrol moduna geçilir veya hat durdurulup operatör onayı beklenir.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Fail-safe ve human override kullanılarak bağımsız tork ve akım sınırıyla motor durdurulur, operatör onayı beklenir.
Girdi manipüle edildi	Monitoring ve fail-safe kullanılarak bozuk veya donmuş görüntü tespit edildiğinde hat güvenli duruşa geçirilir.
Confidence düştü	Confidence threshold ve fallback kullanılarak güven eşiği yüzde 85 altına indiğinde klasik sensör kontrolüne geçilir ve operatöre sorulur.

Bu föyün çıktısı **AI Fail-Safe Decision → Evidence Pack EP 03 + EP 15** başlığına oturur.